整体项目内容由个人和 Gemini 进行思路启发以及完善完成。项目于 jupyter 上运行，除模型加载外无相关运行环境限制。

首先确定了本次项目的大体流程：数据预处理-检索模型-DeBERTa/LLM。

1 数据预处理

在数据预处理部分，选定了数据清洗、二次切割与文本构造、向量化、构建索引并保存的思路。数据清洗部分主要是针对 original_data 中的 full_text 进行文本切分，主要切分为 section_name 和 text 以便于后续处理。

二次切分与文本构造主要基于 text 长度构造包含丰富语义的文本格式“Title: [标题] \n Section: [章节名] \n Content: [内容]”。

向量化过程使用 bge-m3 进行 1024 维向量化处理，最后得到的数据形状为：(文档数, 1024)。

最后构建了 FASSI 索引并进行文件保存为.pkl（文本数据库)和.index（向量索引）

2 检索模型

检索模型存在两种，一种是由 rerank 主导的检索后续由 DeBERTa 进行分类预测；一种是由 LLM 主导的检索，后续仍由 LLM 进行分类预测。

检索函数大体框架为：BM25 与 BGE-M3 同时检索后取并集进行粗排序，随后交由 rerank 模型进行精排序。

若使用 DeBERTa 则返回 rerank-TOP 1，若使用 LLM 则返回 rerank-TOP K。

3 分类模型

DeBERTa 模型获取了其返回参数 Entailment，并由此来决定分类。

LLM 使用了较为详细的 prompt，最终返回包含 "reasoning" (分析原因), "label" (判别结果), 以及 "best_evidence_id" (支持你判断的编号，例如：只需要输出数字，如 "1" 或 "3") 的 JSON。”

整体流程框架大致如下图：



参考文献：

[1] Robertson, S. E., Walker, S., Jones, S., & Hancock-Beaulieu, M. M. (1995). Okapi at TREC-3. In Overview of the Third Text REtrieval Conference (TREC-3) (pp. 109-126). Gaithersburg, MD: NIST.

[2] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Hybrid Filtering. arXiv preprint arXiv:2402.03216.

[3] Xiao, S., Liu, Z., Zhang, P., & Mu, N. (2023). C-Pack: Packaged Resources To Advance General Chinese Embedding. arXiv preprint arXiv:2309.07597.

[4] He, P., Liu, X., Gao, J., & Chen, W. (2021). DeBERTa: Decoding-enhanced BERT with Disentangled Attention. In International Conference on Learning Representations (ICLR).